

Глубинное обучение в обработке звука

Речь и её восприятие

План лекции

- Устройство речевого аппарата
- Производство речи и артикуляция
- Физические модели речевого аппарата
- Кепстр и мел-частотные кепстральные коэффициенты
- Фундаментальная частота
- Психоакустика и восприятие речи


Устройство речевого аппарата

Устройство речевого аппарата

Речевой аппарат включает в себя области от легких до носа, разделенные на несколько подсистем

Гортань делит аппарат на 3 части:


- Подгортанный
- Гортанный
- Надгортанный




Устройство речевого аппарата

Подгортанный аппарат:

- Легкие и диафрагма и мышцы грудной клетки работают вместе для втягивания и выталкивания воздуха
- Речевой процесс начинается из лёгких, которые выталкивают воздух наружу




- Диафрагма – главная мышца, отвечающая за дыхание
- Она представляет собой большую куполообразную мышцу, разделяющую грудную полость от желудка



Устройство речевого аппарата

Гортань:


- Состоит из хрящей и мышц, которые управляют голосовыми связками
- Связки могут сжиматься и разжиматься, создавая вибрации
- Высота голоса зависит от скорости вибрации связок
- Выполняет роль клапана, разделяя лёгкие и желудок



Устройство речевого аппарата

Надгортанный аппарат (речевой тракт):

- Формирует поток воздуха, необходимый для создания различных звуков
- Активные артикуляторы (губы и язык) двигаются к пассивным (зубы) и формируют звуки




Производство речи и артикуляция

Производство речи

Механизм производства речи можно разделить на 4 этапа:


- ***Создание воздушного потока*** – служит источником энергии
- ***Фонация*** – возникновение звука в гортани
- ***Оро-назальный процесс*** – распределение воздуха между ротовой и носовой полостями
- ***Артикуляция*** – формирование звуков благодаря движению артикуляторов



Производство речи

Голосовые связки:

- **Звонкие звуки (*voiced*)** – связки сомкнуты и вибрируют под действием воздуха
- **Глухие звуки (*unvoiced*)** – связки разомкнуты, воздух проходит свободно



Артикуляторы – органы, которые меняют форму речевого тракта и формируют конкретные звуки

Артикуляция гласных

При производстве гласных звуков воздух проходит свободно, без преград

Гласные можно описать 3 признаками:

- Высота языка – влияет на f_1
- Ряд языка (спереди\сзади) – влияет на f_2
- Степень округления губ – влияет на обе форманты

Первые две форманты f_1 и f_2 позволяют отличить гласные буквы друг от друга


Артикуляция согласных

Согласные всегда образуются с помощью какой-либо преграды на пути воздушного потока

Согласные можно описать с помощью 5 признаков:

- ***Работа связок*** – звонкие или глухие
- ***Место артикуляции*** – губы, зубы, нёбо
- ***Способ артикуляции*** – взрыв, трение, дрожание
- ***Путь выхода воздуха*** – рот или нос
- ***Тип преграды*** – центральная или боковая

Производство речи



Физические модели речевого аппарата

Физические модели речевого аппарата

- Все части дыхательного пути выше гортани называются речевым трактом
- Его форма и положение артикуляторов являются решающими для формирования звуков


Чтобы понять механизм производства речи, было предложено несколько моделей, самая популярная из которых – **модель источник-фильтр** (*source-filter model*)

Она описывает процесс создания речи в виде 2 этапов:

- Источник создаёт звук
- Фильтр изменяет этот звук

Модель источник-фильтр

- Источником звука служат голосовые связки, а речевой тракт выступает в роли фильтра, который усиливает или ослабляет определенные частоты



- В самой простой версии этой модели (**Fant, 1960**) не учитывается взаимодействие звуковых волн в речевом тракте и голосовых связках, то есть источник и фильтр работают независимо

Источник

В нашей речи используется 4 основных источника звука

Источник голоса (glottal source):

- Это и есть голосовые связки
- Отвечает за основную высоту тона и гармоника
- Относятся все гласные и звонкие согласные звуки

Придыхание (aspiration source):

- Турбулентный шум при прохождении воздуха через голосовую щель
- Относятся английские *[p]*, *[t]*, *[k]*
- В русском почти не используется

Источник

Источник трения (frication source):

- Турбулентность в местах сужения тракта (зубы губы)
- Относятся фрикативные согласные ф, с, ш


Переходной источник (transient source):

- Происходит резкий выброс давления после полного смыкания
- Относятся взрывные согласные п, т, к

Фильтр

- Звук проходит через речевой тракт, который действует как фильтр: в зависимости от того, как вы расположите язык, губы и зубы, будут усиливаться одни частоты и ослабляться другие


- Фильтр можно представить как однородную трубку длиной 17.5 см
- Один конец трубки закрыт (голосовая щель), другой – открыт (рот)



- Не все волны могут существовать в такой системе
- Остаются волны, которые удовлетворяют определённым граничным условиям


Стоячие волны

- Когда волны доходят до конов струны, они отражаются и накладываются друг на друга
- В некоторых точках струны колебания будут усиливаться (**пучности**), а в других – полностью гаситься (**узлы**)
- Эти точки не перемещаются вдоль струны и создают иллюзию **стоячей волны**



Стоячие волны


Частота основного тона и гармоник зависят от длины струны, ее материала и натяжения



Стоячие волны: интуиция


Струна вибрирует определенным образом:

- Точки на концах всегда остаются неподвижными
- Любые колебания, которые требуют перемещения этих точек будут сопротивляться физическим характеристикам среды и не будут устойчивыми



Стоячие волны: интуиция

Нам подходит случай, когда длина струны равна половине длины волны



Следующий паттерн – тот, где две длины волны вписываются в длину струны



Стоячие волны: интуиция

Итог:

Стоячая волна формируется в случае, когда на длине струны l укладывается целое число полуволн:

$$l = \frac{\lambda}{2}n, \quad \lambda = \frac{2l}{n}$$

$$l = \lambda$$



$$l = \frac{3}{2}\lambda$$




$$l = 2\lambda$$



$$l = \frac{5}{2}\lambda$$



$$l = \frac{3}{4}\lambda$$



Стоячие волны: математика

- Струна, закрепленная с обоих концов, накладывает граничные условия на колебания
- Устойчивыми будут только стоячие волны

Колебания струны описываются линейным однородным дифференциальным уравнением в частных производных гиперболического типа:

$$\frac{\partial^2 U}{\partial t^2} = a^2 \frac{\partial^2 U}{\partial x^2}$$

- $U(x, t)$ — смещение точки струны с координатой x в момент времени t
- $a = \frac{N}{\rho}$ — коэффициент пропорциональности, зависящий от натяжения струны N и ее линейной плотности ρ

Стоячие волны: математика

Решение ищется в виде суммы гармонических колебаний:

$$U(x, t) = \sum_{n=1}^{\infty} \left(a_n \cos\left(\frac{\pi a n t}{l}\right) + b_n \sin\left(\frac{\pi a n t}{l}\right) \right) \sin \frac{\pi n x}{l}$$

Для нахождения окончательного решения нужно найти коэффициенты a_n и b_n , задав начальные условия:

$$u \Big|_{t=0} = f(x), \quad \frac{\partial u}{\partial x} \Big|_{t=0} = g(x)$$

Тогда коэффициенты будут иметь вид:

$$a_n = \frac{2}{l} \int_0^l f(x) \sin \frac{\pi n x}{l} dx, \quad b_n = \frac{2}{\pi n a} \int_0^l g(x) \sin \frac{\pi n x}{l} dx$$

Стоячие волны: математика

Полученное решение можно переписать в виде:

$$U(x, t) = \sum_{n=1}^{\infty} A_n \sin \frac{\pi n x}{l} \sin(\omega_n t + \varphi_n),$$

- $A_n = \sqrt{a_n^2 + b_n^2}$
- $\omega_n = \frac{\pi n a}{l} = \frac{\pi n}{l} \sqrt{\frac{N}{\rho}}$

- Каждый член ряда описывает гармонические колебания точек струны с амплитудой $\sin \frac{\pi n x}{l}$, частотой ω_n и начальной фазой φ_n
- Амплитуды гармоник зависят не только от номера n , но и от переменной x

Стоячие волны: математика

Для закрепленной струны граничные условия требуют, чтобы смещение $U(x, t)$ на концах было равно нулю:

$$U(0, t) = U(l, t) = 0$$

Чтобы $\sin \frac{\pi n x}{l}$ был равен нулю на концах струны, аргумент синуса должен быть кратен π :

$$\sin\left(\frac{\pi n \cdot 0}{l}\right) = 0, \quad \sin\left(\frac{\pi n \cdot l}{l}\right) = \sin(n\pi) = 0$$


Вспомним волновое число

Получаем:

$$l = \frac{\lambda}{2} n, \quad \lambda = \frac{2l}{n}$$

Стоячие волны: случай трубки

Для воздушной трубки закрытый конец должен быть узлом, а открытый конец — пучностью



Стоячие волны: случай трубки

Для трубки, открытой с одного конца, стоячая волна будет возникать в случае:

$$l = \frac{(2n - 1)}{4} \lambda$$

Вспомним, что $\lambda = \frac{v}{f}$, тогда:

$$l = \frac{(2n - 1)}{4f} v \quad \Rightarrow \quad f_n = \frac{(2n - 1)}{4l} v$$

Длина голосового тракта среднестатистического мужчины составляет 17 см, а скорость звука в воздухе $340 \frac{\text{м}}{\text{с}}$:

$$f_1 = \frac{1}{4 \cdot 0.17} \cdot 340 = 500 \text{ Гц}$$



$$f_2 = \frac{3}{4 \cdot 0.17} \cdot 340 = 1500 \text{ Гц}$$

Кепстр и мел-кепстральные коэффициенты

Недостатки спектра

Спектр содержит слишком много сырой информации

Можно точнее увидеть свойства сигнала, глядя на его лог-спектр



Лог-спектр имеет периодическую структуру и его пики соответствуют основным гармоникам, присутствующим в сигнале

Идея:

- Представим спектр, как периодический сигнал и будем анализировать его с помощью преобразования Фурье

Кепстр

Кепстр – это результат применения обратного преобразования Фурье к логарифму спектра мощности:

$$C\{x(t)\} = |F^{-1}\{\log(|F\{x(t)\}|^2)\}|^2$$

- $F\{\cdot\}$ и $F^{-1}\{\cdot\}$ – прямое и обратное преобразования Фурье

О кепстре можно думать как о спектре спектра сигнала


Кепстр (*cepstrum*) – это анаграмма слова **спектр** (*spectrum*)

Алгоритм получения кепстра:

- Считаем дискретное преобразование Фурье исходного сигнала
- Получаем лог-спектр
- К лог-спектру применяем обратное преобразование Фурье

Кепстр

- Полученный результат находится ни в частотной ни во временной области
- Авторы решили называть получившуюся область ***quefrequency domain*** (анаграмма ***frequency***)



Мел-частотные кепстральные коэффициенты

- Обычный спектр содержит тысячи точек
- Человеческий слух лучше различает низкие частоты

Попробуем построить что-то, что различает звуки так же, как человек и упакуем все в небольшой вектор


Полученные коэффициенты получили название *мел-частотные кепстральные коэффициенты* (*Mel – Frequency Cepstral Coefficients, MFCC*)

MFCC часто применяются для идентификации говорящего, классификации эмоций и многих других задач

Мел-частотные кепстральные коэффициенты

Алгоритм:

- Вычисляем дискретное преобразование Фурье
- Накладываем на спектр набор треугольных мел-фильтров
- Считаем логарифм от полученных значений
- Вычисляем дискретное косинусное преобразование Фурье




Фундаментальная частота

Фундаментальная частота


- **Основная частота** f_0 — самая низкая частота в сигнале
- Она определяется частотой колебания голосовых связок

- f_0 обычно не стационарна и меняется в пределах предложения
- Её можно использовать для обозначения акцентов или вопросов



Фундаментальная частота

Обычно фундаментальные частоты лежат в диапазоне от 80 Гц до 450 Гц



Фундаментальная частота

Фундаментальная частота видна в нескольких различных областях:

- В сигнале как повторение через каждые T отсчётов
- В автокорреляции как пик на лаге T
- В спектре как пик на частоте $f_0 = \frac{f_s}{T}$
- В кепстре как пик на *quefrency* в момент T


Фундаментальная частота

От простых методов индустрия перешла к сложным вероятностным моделям

Популярные алгоритмы:

- *YIN*
- *pYIN*
- *DIO*
- *HARVEST*
- *REAPER*

Фундаментальная частота



Психоакустика и восприятие звука

Восприятие речи

Мы привыкли описывать звуки субъективными терминами:

- Громкий или тихий
- Высокий или низкий

Ученые предпочитают использовать характеристики, которые можно измерить с помощью приборов

Громкость

Высота

Тембр

Амплитуда

Частота

Спектральный состав


Огибающая

Амплитуда и громкость

Громкость – это наше субъективное ощущение силы звука (его звукового давления)

В основном, человеческое восприятие громкости основано на амплитуде звукового давления на барабанную перепонку

Если все остальные характеристики равны, то звуки более высокой амплитуды воспринимаются как более громкие




Громкость и частота

Амплитуда – не единственный фактор восприятия громкости

- Наш слух устроен так, что лучше воспринимает звуки средних частот от 2000 Гц до 4000 Гц
- Для большинства людей звук с частотой 3000 Гц будет звучать громче звука с частотой 100 Гц


Учёные провели специальные психоакустические тесты, которые позволили построить контуры одинаковой громкости (**кривые Флетчера-Мэнсона, Fletcher Munson curves**)



Громкость и частота

В течение столетия проводилось множество уточняющих исследований

Последняя и наиболее точная редакция
зафиксирована в международном стандарте
ISO 226:2003



Громкость и частота


Человек воспринимает громкость по-разному в зависимости от частоты звука

- **Фон** – единица измерения воспринимаемой громкости

- На частоте 1000 Гц:

$$1 \text{ фон} = 1 \text{ дБ}$$

- **Изофоны** – кривые одинаковой громкости



Высота и частота

Помимо амплитуды наше восприятие звука напрямую связано и с частотой

- Диапазон слышимости человека лежит в пределах от 20 Гц до 20 000 Гц
- Звук с частотой ниже 20 Гц называется *инфразвуком*, а с частотой выше 20 000 Гц — *ультразвуком*




Высота и частота


- Не все звуки имеют определенную высоту
- Чтобы мы могли оценить высоту, звуковая волна должна быть квазипериодической

Примерами таких сигналов являются звуки музыкальных инструментов и звуки животных

Пианино



Человеческая речь



Способность воспринимать высоту звука связана с наличием в звуковом сигнале квазипериодической составляющей

Высота и частота

Наш слух более чувствителен к изменениям низких частот

Мы легко отличаем разницу между 400 Гц и 450 Гц, но отличить звуки 5000 Гц и 5050 Гц сложнее

- Поэтому был придуман способ измерять высоту звука так, чтобы одинаковые интервалы по частоте воспринимались нами так же одинаково, вне зависимости от области частот
- Единицу измерения такой величины называли *мел*

Высота и частота

Мел - это психофизическая единица высоты звука


Формула перехода от герц к мел-шкале была выведена эмпирически с помощью проведения большого количества психоакустических тестов

- Для перевода из герц в мел-шкалу используют формулу:

$$m = 1127 \cdot \ln\left(1 + \frac{f}{700}\right), \quad m = 2595 \cdot \log_{10}\left(1 + \frac{f}{700}\right)$$

- Обратный переход:



$$f = 700 \cdot \left(e^{\frac{m}{1127}} - 1\right) \quad f = 700 \cdot \left(10^{\frac{m}{2595}} - 1\right)$$



Тембр и спектральный состав

Тембр – это характеристика звука, которая позволяет отличать звуки одинаковой частоты и громкости

Если фортепиано и флейта играют одну и ту же мелодию с одинаковой громкостью и частотой, мы все равно можем отличить их друг от друга благодаря уникальной окраске звука каждого инструмента




Тембр и спектральный состав


В основном, тембр определяется распределением энергии по частотам

Однако статичного спектра недостаточно – важно то, как он изменяется со временем

- Начало звука (атака) и его окончание (затухание) существенно влияют на наше восприятие
- Быстрая атака и медленно затухание фортепиано создают другое впечатление, чем резкая атака и быстрое затухание у гитары



Восприятие речи



Спасибо за внимание!